向内破

大语言模型能否靠自身信号学会利用已有知识

陈威宇（Daniel Chen）

Bocconi × HEC Paris

2026 年 10 月

摘要

本研究考察语言模型单步事实可答、组合却失败的知识利用缺口。Qwen3 系列测量支持该缺口存在；自身生成目标的训练带来小幅迁移收益，打乱目标显著损害表现。置信度筛选未稳定优于随机筛选；错目标与对目标的收益尚难区分。结果支持继续研究内部知识利用，但不足以确认一般性的向内进化机制。

3 研究问题与动机

语言模型可能分别回答“某人物出生在哪个国家”和“该国的某个属性是什么”，却无法直接回答这两步组合而成的问题。这种现象将**拥有可提取的事实**与**能够在当前问题中调用并组合事实**区分开来。本文沿用“知识利用缺口”：只在两步均能独立答对的题上，统计组合回答失败的比例。[S0,S1]

“向外进化”通过外部事实、标准答案或任务反馈补充模型能力；“向内进化”尝试利用模型自身产生的答案或内部信号，改善已有知识的调用。二者并非互斥，本研究关注的是：**在训练目标不直接采用标准答案时，自身信号能否帮助组合泛化？**这里的“已有知识”是单步行为上的操作性定义，并非对模型内部知识存储的完整刻画。

研究分为三个层次：先确认缺口及评分误差；再考察桥接实体能否被内部读出、推理时回填是否有效；最后比较自身目标、置信度筛选及答案打乱等训练对照。已有结果主要来自单一事实数据集和 Qwen3，属于探索性证据。

报告的证据边界

正文数值来自本地结果及重新计算，误差线为训练种子间样本标准差。“待核实”表示仅能在交接文档中找到记录，缺少相应原始结果。所有表图的来源编号对应随附 `SOURCE_MAP.txt`；原始文件哈希记录于 `source_sha256.json`。报告没有覆盖或改写任何旧结果。

4 实验设置与统计口径

数据采用 Compositional Celebrities，围绕人物、出生国和国家属性构造两步事实问题。干净类别定义为 `category` 以 `birthplace` 开头、且不含 `common_name`。缺口测量覆盖 Qwen3 的不同规模，训练主模型为 Qwen3-14B。[S1,S9] **切分原则**。人物与类别族分别切分，C 同时排除训练人物和训练类别族，而

表 1: 主要设置；参数来自保存配置及训练脚本。[S8,S10,S11,S14]

项目	设置
模型	Qwen3：0.6B、1.7B、8B、14B；训练主模型 14B
训练问题	组合问题；全量池 864 条，包含首都、区号、经纬度类别
测试切分	A：训练类别、新人物；B：新类别、训练人物；C：新类别、新人物
新类别族	货币、顶级域名、国家数字代码；C 为主要迁移指标
评估数量	A/B/C 各 500 条，固定评估抽样种子 0
训练随机性	三个训练种子：0、1、2；每次从基础模型独立初始化适配器
LoRA	rank 16，alpha 32，dropout 0.05；学习率 10^{-4}，2 epochs，batch 8
目标生成	自身回答第一步，再将该回答放入上下文生成组合训练目标
对照数量	exp8 半量 432 条；exp10 三条件均为 228 条

不是仅把相同题型的题目随机拆分。exp8/exp9 冻结自身目标，改变筛选或目标分配；exp10 用标准答案划分对错，但标准答案不作为训练文本目标。因而 exp10 是有标准答案参与分组的机制诊断，不能称为完全无监督的样本选择。[S10,S11,S14]

评分。旧评分对字符串归一化，会误删数字的负号和小数点。修订评分对数字保留符号，按数学 floor 向下取整比较，同时检查截断取整的敏感性。缺口表采用修订评分；exp8/exp9 保留其历史评分，exp10 采用 floor。exp10 的 C 组组合结果在旧、floor、截断三种评分下相同，其他指标仍应区分版本。[S1,S7]

$$K = \{i : q_{1,i} = 1 \wedge q_{2,i} = 1\}, \qquad \mathrm{gap}_{\mathrm{clear}} = \frac{\sum_{i \in K}(1 - \mathrm{clear}_i)}{|K|}.$$

$\mathrm{gap}_{\mathrm{ctx}}$ 使用相同分母，将组合回答替换为提供中间事实后的回答。单步独立作答正确不等于组合过程中实际成功调用该事实。

统计。组合准确率均值及标准差来自三个训练种子；配对检验在同一种子、同一批评估题上进行。逐题差异使用 McNemar 检验，exp10 的多重比较采用分析文件中的 Holm 校正。种子均值区间采用配对种子的 t 区间，仅反映种子波动；三个种子无法充分覆盖训练与数据不确定性。[S5,S6,S7]

5 实验结果

5.1 缺口测量与失败分类

表 2: 干净类别、各模型自身的两步已知集合；floor 评分。百分比的分母为“已知题数”。[S1]

规模	已知题数	gap_clear（%）	gap_ctx（%）
0.6B	143	42.7	60.1
1.7B	947	74.7	65.4
8B	1902	39.5	12.8
14B	2379	33.8	10.9

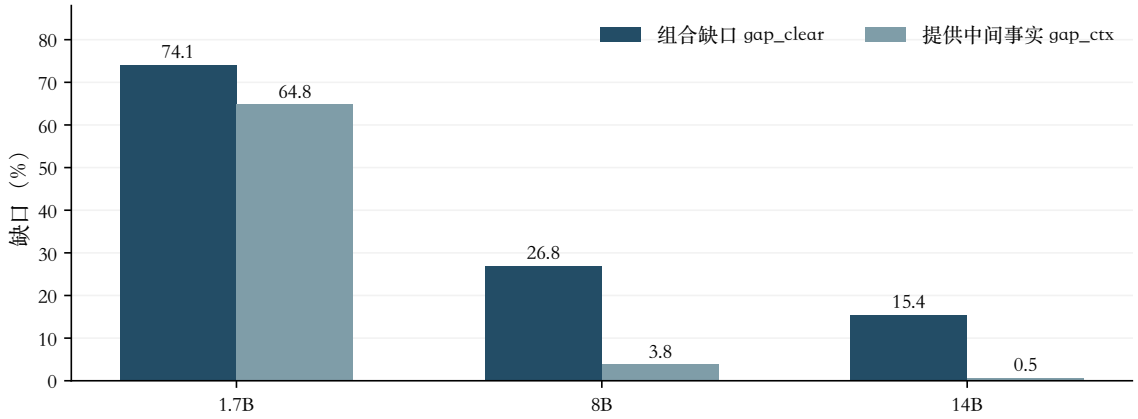


图 1: 同一批 738 道题：三种规模均在 floor 评分下独立答对两步。此共同集合比表 2 更容易，不能混用分母。[S1；各规模 rescored 文件]

14B 的缺口约为三分之一，提供中间事实后明显缩小（表 2）。只比较 8B/14B 同时掌握的题，旧评分共有 1628 题，缺口为 35.9% → 23.6%；floor 评分共有 1613 题，为 35.5% → 23.2%。因此“约 36% → 24%”有文件支持，但不是所有题上的整体规模曲线。[S1；rescored_8B/14B] 分类采用逐题模型辅助审阅、拿

表 3: 从旧评分的 818 道失败题中固定种子 7 抽取 120 题。[S2]

标注	数量	占比（%）
GENUINE	94	78.3
AMBIGUOUS_GOLD	12	10.0
FORMAT	8	6.7
SCORER_ERROR	6	5.0

不准归真错的保守规则，**尚未经过独立人工复核**。历史货币、属性类型及评分程序造成部分争议，不能将样本比例直接当作整个缺口的精确真错率。[S2]

结论：行为缺口及同题规模差异支持“事实可答与组合可答并不等价”；分类提示该现象不全由格式和评分误差解释。

5.2 内部激活：桥接实体可被读出

表 4: 逻辑透镜：排除桥接实体与最终答案共享首词元的题；命中为任一层 rank < 10。[S3,S4,S9；Qwen3-14B tokenizer]

组别	原始样本	排除数	命中/保留	命中率（%）
失败组	300	12	243/288	84.4
成功组	300	22	254/278	91.4

过滤使用标准答案全部别名及带前导空格的词元编码，避免共同首词元把最终答案误当成桥接实体。约 84% 与 91% 的历史概括在这一口径下可复现。这里测量的是首词元可解码性，并非完整实体表示，也不直接代表该实体被后续计算因果地使用。[S3,S9；build_figures.py]

结论：失败时桥接信号仍常可读出，提示问题可能涉及知识调用与组合；透镜本身不能确认具体失效机制。

5.3 推理时干预：局部修复与整体损害

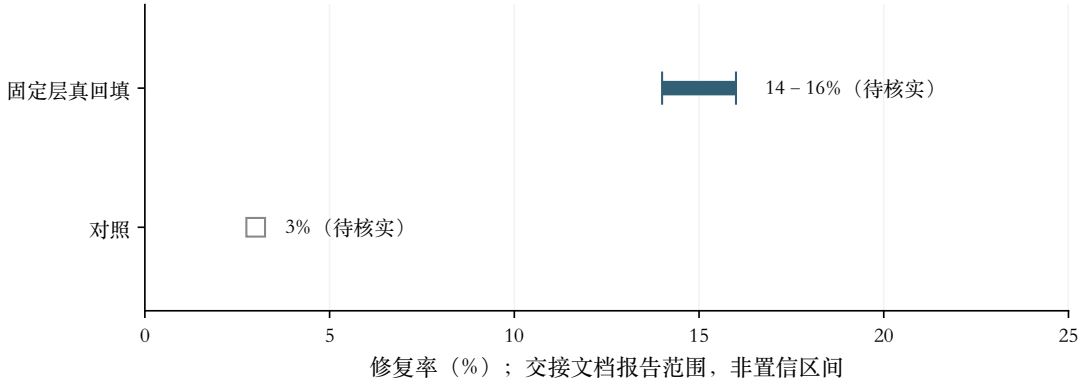


图 3: 交接文档中的固定层真回填与对照修复率。范围是文档记录，并非误差条或置信区间；缺原始回填文件，全部待核实。[S0]

表 5: 推理时干预的历史记录与核验状态。[S0]

条件	交接记录	状态
固定层回填	修复 14–16%，对照 3%；$p < 10^{-8}$	待核实
整体影响	原正确题被破坏，净效果为负	待核实
置信度门控	净效果约为 0	待核实

修复率只描述原本答错的题；总体净变化还必须扣除原本答对、干预后变错的题。仅凭较高修复率不足以评价部署收益。由于本地缺少原始干预与配对预测文件，本节不作为已复核的因果证据。

结论：历史记录提示简单回填存在破坏性；当前可审计材料不足以确认其效果大小与显著性。

5.4 向内训练：小幅组合泛化收益

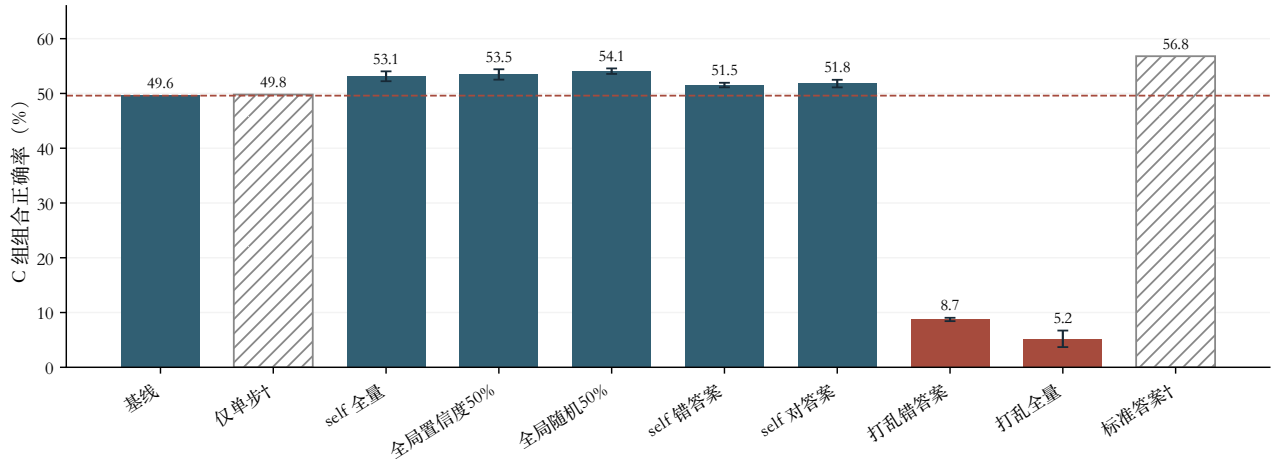


图 **2:** C 组各条件正确率；虚线为基础模型，误差线为三种子样本标准差。斜线柱 † 是交接记录、待核实的单次结果。全量 864 条、半量 432 条、对错诊断 228 条，跨条件柱高不代表等量因果比较。[S0,S5,S6,S7]

表 **6:** self 全量在固定切分上的组合正确率；均值 ± 标准差。[S5,S6]

测试集	基线（%）	self（%）	增益（百分点）
A：新人物	39.0	47.9 ± 0.5	+8.9
B：新类别	44.6	50.8 ± 1.6	+6.2
C：两者都新	49.6	53.1 ± 0.9	+3.5

C 组 self 三种子均值为 53.1 ± 0.9%，高于基础模型（图 2）。历史仅单步训练 49.8%、标准答案训练 56.8% 均只能追溯至交接文档，待核实；标准答案条件为单次运行，不能与三种子均值作稳定性对等比较。[S0,S5,S6]

单步保留需谨慎表述。exp8 保存的 C 组单步检查只覆盖固定的前 150 题。第一步从 84.7% → 86.4%，第二步从 74.0% → 72.4%（训练后取三种子均值）。这支持第一步大致保持，但第二步略有回落，因此不能宣称所有单步能力均不下降。[S13]

幅度与检验。C 组收益为数个百分点，属于小幅改善。逐种子配对结果并非每次都显著，不能以三次运行方向相同替代全面稳定性验证。跨人物与类别族的切分使该收益比训练题记忆更有解释价值，但仍不能排除更一般的任务适应。[S5,S6]

结论：自身目标训练支持有限的组合迁移收益；尚不足以确认一般性、自主持续提升，也不能宣称完全不遗忘。

5.5 置信度过滤：目标更准，迁移未稳定更好

表 7: 目标质量与 C 组结果。质量列为冻结样本/随机种子 0；C 为三训练种子均值 ± 标准差。类别内两条件每类保留相同数量。[S5,S6]

条件	训练条数	目标正确率（%）	C 正确率（%）
全量	864	51.5	53.1 ± 0.9
全局置信度 50%	432	70.6	53.5 ± 0.9
全局随机 50%	432	49.8	54.1 ± 0.5
类别内置信度 50%	432	—	52.5 ± 1.8
类别内随机 50%	432	—	52.5 ± 0.9

目标整句平均对数概率区分正确与错误的 AUROC 为 0.722（全量训练池）。它只衡量排序诊断，不表示概率校准；标准答案不参与 exp8/exp9 的训练目标或筛选。置信度筛选显著提高目标正确率，却未超过同数量随机筛选的 C 组均值；类别内比较也没有稳定优势。[S5,S6]

结论：置信度可预测部分目标正确性，但筛掉低置信度样本并未稳定改善组合迁移；“C 无提升”应指无额外筛选收益，而非低于基线。

5.6 对照分析：内容对应重要，正确性作用未分离

表 8: exp10：三条件各 228 条，类别数量匹配；C 组各 500 题，floor 评分。单步列为三种子均值。[S7,S10]

条件	C（%）	增益（百分点）	第一步（%）	第二步（%）
self 错答案	51.5 ± 0.4	+1.9	84.1	78.3
self 对答案	51.8 ± 0.7	+2.2	84.5	77.3
打乱错答案	8.7 ± 0.3	-40.9	53.0	72.3

自身错目标与打乱错目标使用同一批问题，后者在类别内改变目标对应关系。全量打乱的 C 结果为 5.2 ± 1.5%（exp9），打乱错目标同样大幅下降（表 8）。这不支持“只熟悉题型就足够”的强解释；但打乱亦引入矛盾监督和分布扰动，不能据此唯一归因于知识内容。[S6,S7,S10,S11]

self 错答案相对 self 对答案的均值差为 -0.27 个百分点，配对种子均值 95% 区间 [-1.52, 0.98]；两者未检出稳定差异，**不是等效性结论**。对基础模型的改善在逐题 Holm 校正后也未达到显著。正确组问题与错误组不同，尚残留难度及语义正确性混杂。[S7]

结论：结果提示问题与自身目标的对应关系重要；尚未分离“真实正确性”与“模型自身一致性”的独立作用。

6 讨论：结论、撤回与局限

目前支持的四条结论：

1. 单步可答并不保证组合可答；同题规模比较与中间事实上下文提示知识利用存在瓶颈。[S1]
2. 失败题中桥接实体常可读出，提示“无可读信号”不能解释全部失败；这仍是相关性观察。[S3,S9]
3. 自身目标训练在严格 C 切分上带来小幅平均收益；目标与问题的任意打乱会造成明显损害。[S5,S6,S7]
4. 目标正确率与下游迁移收益并非简单单调对应；置信度排序优势未转化为稳定筛选收益。[S5,S6]

已撤回或不再使用的四种强说法：

1. “答案可从隐藏层读出，就说明模型实际使用了该知识。”缺少因果识别。
2. “提高目标正确率，组合能力必然更好。”筛选实验不支持该必然关系。
3. “错答案和对答案一样有效，所以一致性才是机制。”未检出差异不能确认等效，更不能唯一确定机制。
4. “向内训练完全不遗忘，并能持续自我进化。”单步有回落，多轮及跨模型家族尚未验证。

局限。仅一个模型家族与一个事实组合基准；训练种子少、切分固定，存在探索性多重比较。对错标签受标准答案宽窄影响，120 题分类尚未独立人工复核。逻辑透镜仅看首词元，内部可解码不代表因果使用。旧回填、hops、gold 原始文件缺失，相关数字均待核实；不同实验训练量和评分版本亦限制横向比较。[S0,S1,S2,S5,S6,S7]

7 下一步研究

1. **迭代自我训练：**用新人物逐轮再生成自身目标，对照每轮从基础模型重新训练；监测错误题置信度、单步遗忘及累计训练预算。
2. **跨结构迁移：**改变关系链长度、关系类型及问题表达，固定数据量与优化步数，检验收益是否超出当前模板。
3. **隐空间探针：**与因果干预结合，排除词元重叠、读出器和位置混杂，检验桥接表示是否参与后续计算。
4. **第二个模型家族：**复现冻结目标、随机筛选、打乱目标和正确性诊断，检验现象适用范围。
5. **文献对比：**区分组合缺口、内部多跳时序、上下文蒸馏及自生成推理训练；明确本研究新增的对照与尚未解决的机制。

参考文献

[1] Press, O., et al. (2022). Measuring and Narrowing the Compositionality Gap in Language Models. arXiv:2210.03350.

[2] Biran, E., et al. (2024). Hopping Too Late: Exploring the Limitations of Large Language Models on Multi-Hop Queries. arXiv:2406.12775.

[3] Snell, C., Klein, D., & Zhong, R. (2022). Learning by Distilling Context. arXiv:2209.15189.

[4] Zelikman, E., et al. (2022). STaR: Bootstrapping Reasoning With Reasoning. arXiv:2203.14465.

[5] Liu, X., et al. (2026). Layer-Order Inversion: Rethinking Latent Multi-Hop Reasoning in Large Language Models. arXiv:2601.03542.