向内破：大语言模型能否靠自身信号学会利用已有知识

陈威宇（Daniel Chen） Bocconi × HEC Paris

2026 年 10 月 · 最终阶段版（核验日期：2026-10-11）

摘要 本研究检验模型能否以自生成信号改善已有事实的组合使用。经评分审计与多种对照，观察到组合性缺口及小幅迁移收益；打乱目标显著损害表现。置信度过滤与多轮迭代尚无稳定额外优势，并伴随部分单步能力回落。结果支持继续研究知识利用，但不足以支持持续自我提升或特定内部机制。

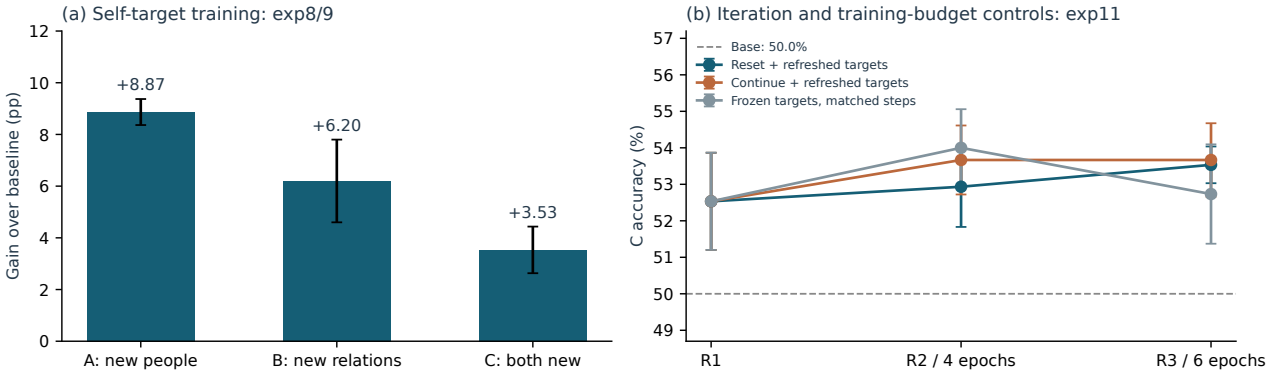


图 1: 核心证据：左为全量 self 在 A/B/C 的收益；右为 exp11 的 C 组轨迹。误差线为三个训练种子的样本标准差，不是置信区间。左右实验基线分别为 49.6%（C）与 50.0%，不得混合比较。来源：E8、E9、E11。

三条核心发现

1. **问题存在**。14B 在两步单问均正确的样本中，仍有 33.80% 组合失败；给出正确中间事实后为 10.93%。这支持研究知识利用障碍，而非仅增加事实覆盖。〔G〕
2. **自身输出能提供有限训练价值**。全量 self 的 C 组为 53.13% ± 0.90，较基线提高 3.53 个百分点；类别内打乱后为 5.20% ± 1.51。对应关系重要，但内部“自我对齐”机制尚未被识别。〔E8、E9〕
3. **尚未得到持续改进的可靠信号**。exp11 重置 R3 为 53.53% ± 0.50，接续 R3 为 53.67% ± 1.01；均未稳定超过匹配预算对照，部分第二步能力下降。〔E11〕

本节判断：本阶段止于 exp11。建议保留“知识利用”问题，修订“仅刷新输出目标即可持续提升”的路线；下一阶段先选择可检验的信号与迁移目标，再决定是否投入新实验。当前结果是有限的研究信号，不是通用能力突破。

1 研究问题与证据路线

1.1 从“拥有知识”到“在需要时使用知识”

两步问题可写作 $x \to z \to y$：例如人物的出生国为中间实体 z，再由国家属性得到答案 y。模型分别回答两步正确，却在直接回答组合问题时失败，构成操作性定义上的“知识利用缺口”。这里的“知道”仅指给定提示与解码条件下的单步正确，不能等同于可完整定位的事实存储。

“向外进化”通过新语料、外部教师或反馈扩展监督；“向内进化”尝试利用当前模型自身可产生或可读取的信号，改善已有能力的调用。本研究实际检验的是后者的一个窄版本：**以自生成答案监督组合问题的直接回答**。预训练本身当然包含外部知识，因此并不声称信息完全自足。

1.2 阶段假设与实验顺序

三个层次必须分开：H1，组合性缺口具有实质内容；H2，自生成监督能够产生留出集收益；H3，刷新自身信号能够在匹配预算下带来可重复的额外收益。内部实体可读性、行为收益与因果机制也分别对应不同证据强度。

表 1: exp1–exp11 的问题、实验与证据状态。编号为历史实验编号；不把缺失原始记录的结果当作已复核证据。

实验	核心问题	本报告处理
exp1	缺口与规模变化	重评分、共同已知题交集；数值可复核。
exp2	中间实体是否可读	逻辑透镜；排除首词元重叠，保留读出限制。
exp3	逐层回填探索	探索性层选择；原始结果未查到，移入附录。
exp4	固定层回填	修复与破坏必须并看；原始结果未查到。
exp5	置信度门控干预	历史记录保留，净收益数字待核实。
exp6/6b	self 训练及透镜变化	方案作为前驱；历史 gold/hops 与透镜机制数字待核实。
exp7	评分与类别审计	严格数值评分、别名与干净类别；与后续复核共同使用。
exp8	全量与过滤训练	三种子；全局置信度与随机筛选对照。
exp9	对应关系与类别构成	类别内打乱；类别内等量过滤对照。
exp10	正确性与自身目标	类别配额匹配的错 / 对 / 打乱错目标，各 228 条。
exp11	迭代是否超越预算效应	重置、接续、固定目标预算对照；三个种子，三轮。

来源：H（历史目的与状态）、G/L/A（测量与审计）、E8–E11（复核结果）、P（协议及代码）。完整路径在附录。

本节判断：本阶段形成的是“测量问题—尝试干预—训练对照—检验迭代”的证据链；并非每个历史实验都具有同等可复现性。

2 实验设置与统计口径

2.1 模型、任务与切分

使用 Compositional Celebrities，测量覆盖 Qwen3-0.6B、1.7B、8B、14B，训练主模型为 Qwen3-14B。干净测量集保留 `birthplace` 系列并排除 `common_name`；不将全部类别混为同一种二跳结构。修订口径的测量题池含 4,207 题。〔G、P〕

训练类别族为首都、国际电话区号、经纬度；经纬度含两个具体类别。留出族为货币、顶级域名与国家数字代码，货币的不同表达作为同一族。人物由名称 MD5 的奇偶性划分；评估抽样种子固定为 0，训练种子为 0、1、2。A 使用新人物和已见类别族；B 使用已见人物和新类别族；C 同时使用新人物与新类别族，是主结果。每组固定 500 题；全量训练为 216 位人物、864 条问题。〔P、E8、E11〕

这不是完全独立的知识域迁移：训练和测试仍共享出生国桥接结构及国家属性域；同一人物或国家可贡献多个相关样本。C 排除了训练人物和训练类别族，**没有排除所有桥接国家与关联事实**。

2.2 自生成监督与优化

先由教师模型独立回答第一步，再把自己的第一步答案作为背景，回答组合问题。由此生成目标 $\tilde{y}$；学生训练时输入不含该背景的原组合问题 q，最小化答案 token 的交叉熵：

$$\tilde{z} = f_{\theta_T}(q_1), \quad \tilde{y} = f_{\theta_T}(q;\ \text{背景} = \tilde{z}), \qquad \mathcal{L} = -\sum_{t \in \text{答案}} \log p_{\theta_S}(\tilde{y}_t \mid q, \tilde{y}_{<t}).$$

提示 token 不计入损失；标准答案不进入 self 训练目标。exp10 用标准答案划分子集，因此是有标签的机制诊断，不能称为全流程无监督。〔P〕

表 2: 主训练配置与解码；exp11 从运行配置和代码核对。

项目	设置
LoRA	rank 16，alpha 32，dropout 0.05；注意力 q/k/v/o 与 MLP gate/up/down 投影。
优化	AdamW，学习率 10^{-4}，weight decay 0；批量 8，每轮 2 epochs，梯度范数截断 1。
exp11 步数	全量每轮 216 步；学习率有 20 步预热因子与线性衰减；重启训练时优化器和调度器重置。
数值与解码	BF16、梯度检查点；贪心生成，最多 24 个新 token；非显式长思维链设置。
资源范围	单 GPU 作业设计；本报告未重新启动 GPU 实验。硬件峰值显存和吞吐未形成完整基准记录。

2.3 评分与不确定性

旧评分与修订评分分开报告。修订数值评分保留正负号、小数与方向，拒绝多候选数字；默认 floor，并提供 truncate 敏感性检查。文本实体沿用原别名评分，因此仍有误判空间。〔P、G〕

“±”均为三个训练种子的**样本标准差**，百分点记为 pp。配对比较在同一评估题上统计改对 / 改错，采用双侧精确 McNemar；种子配对差值另给 t 型 95% 区间（自由度 2）。种子不是额外独立的测试题。exp11 主 C 组检验族为 54 项，单步为 42 项，分别做 Holm 校正。区间仅描述种子变化，不能覆盖所有数据抽样、题间相关或研究者选择的不确定性。〔E11〕

3 缺口测量与规模比较：exp1、exp7

令 K_i 表示两步单问均正确；组合缺口定义为 Pr(组合错 | K_i)。`gap_ctx` 在同一条件分母上测量提供**正确**中间事实后的组合错误率；它与训练时使用自己的中间答案不同。

表 3: 各模型自身已知子集上的缺口（%，修订 floor 评分）。分母随模型改变，不是同题规模比较。

模型	已知题数	组合错数	gap_clear	gap_ctx
0.6B	143	61	42.66	60.14
1.7B	947	707	74.66	65.36
8B	1902	752	39.54	12.83
14B	2379	804	33.80	10.93

来源：G，`category=CLEAN`，`modes.floor`。14B 为 804/2379，给背景后为 10.93%；描述的是该操作性子集，而非模型所有知识。

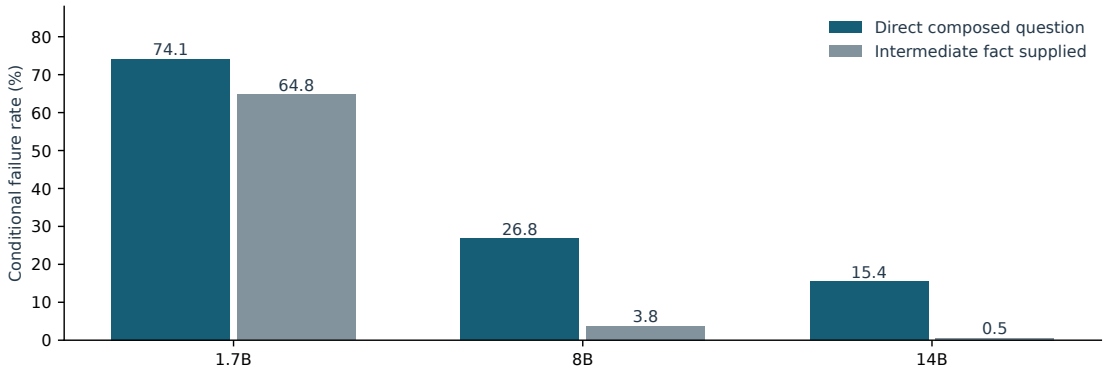


图 2: 跨规模严格同题比较：三种模型两步均答对的共同 738 题。1.7B / 8B / 14B 的 gap_clear 分别为 74.12 / 26.83 / 15.45%，gap_ctx 为 64.77 / 3.79 / 0.54%。来源：G 的三个逐题重评分文件，本报告重新取交集计算。

0.6B 的条件缺口低于 1.7B，且提供背景后的缺口反而更大，不能据此认为小模型更善于组合：其已知子集只有 143 题，与其他规模的条件样本不同。选择效应及提示适应性都是可能解释，**尚未被本实验单独识别**。图 2 仅对较大三个模型取共同交集，不据此补写 0.6B 的因果解释。

旧报告的“8B 约 36% 到 14B 约 24%”来自两模型共同已知集：旧评分为 35.87% → 23.59%（1,628 题），修订评分为 35.46% → 23.19%（1,613 题）。图 2 的三模型交集更小，数字不同并不构成矛盾。〔G〕

对旧评分下 818 个合格失败样本，以种子 7 抽取 120 题逐题模型辅助分类：94 题判为实质错误，12 题为标准答案歧义，8 题为格式，6 题为评分错误；实质错误占 78.33%。这不是独立人工盲审，且不确定案例被保守归入实质错误，不能当作无偏的“真错比例”估计。〔A〕

本节判断：组合性缺口在重评分和共同样本比较后仍存在；规模增大与显式中间事实能缩小缺口，但当前实验没有识别唯一成因。

4 内部可读性与推理时干预：exp2–exp6b

4.1 逻辑透镜发现了什么

将中间层残差状态经最终归一化与词表读出映射为 token 分数，检查中间实体别名首 token 的最佳名次。该透镜沿用输出层的读出坐标，因此属于**可读性诊断**，不是对隐藏状态所含全部信息的完整测量。失败与成功组分别抽取 300 题，剔除任何中间实体 / 最终答案别名首词元重叠后，再判断是否在任一层进入 top-10。〔L〕

表 4: 去首词元重叠后的中间实体可读性。命中指首 token 在至少一层可读，不指完整实体生成。

组别	原始题数	排除数	命中 / 保留	命中率（%）
组合失败	300	12	243/288	84.38
组合成功	300	22	254/278	91.37

来源：L 原始 `lens_items.jsonl` 及先前过滤分析。本次核验原始输入哈希未变；过滤结果沿用已保存派生数据，未重新下载 tokenizer 重建过滤。

失败组的中间答案经常可读，支持“失败不总等于中间实体完全没有相关激活”。但这种激活可能是并行联想、浅层词汇关联或未被后续读取的信息。首 token 命中也可能高估完整实体表征。

对于“前 30 层几乎读不到”的观察，合理结论是**当前读出方法在早层不敏感**；不能反推早层没有信息，更不能把晚层可读性直接解释为推理启动时刻。表 4 汇总的是跨层是否命中，不构成精确时间定位。〔L〕

4.2 从读出到干预，证据为何需要降级

exp3 探索把单步问题激活回填到组合问题；exp4 采用固定层和对照，以区分真实桥接信号与一般扰动；exp5 再用置信度门控。干预质量应同时看修复、破坏与净准确率，不能仅以“修好了多少失败题”评价。历史交接记录提示存在修复与副作用并存的情况，但本地未查到支持原汇总数字的逐题回填 / 门控结果。〔H〕

因此，本版**不再绘制历史回填修复率图，也不将其 p 值列为已验证发现**。附录保留待核实条目，避免丢失研究过程；这个处理不等于重新判定历史结果为假。

exp6 将工作重心转为 self 训练，exp6b 试图用透镜变化解释训练机制。原始 gold、hops 和部分透镜比较尚不足以复核；后续 exp8–exp11 提供的行为证据可以使用，但不能替代这些缺失对照的独立复现。

4.3 与已有工作的关系

组合性缺口的测量与 Press 等的 compositionality gap 相衔接；Biran 等的 *Hopping Too Late* 提供了层间知识组合的机制背景。这里的两阶段目标生成更接近上下文蒸馏：教师在额外背景中作答，学生学习直接回答。与 STaR 使用推理轨迹自举相比，本实验主要训练短答案而非验证后的完整推理轨迹。Layer-Order Inversion 提供另一个结构性视角，但本实验未复现其方法，不能借用其机制结论。[1, 2, 3, 4, 5]

本节判断：已经有“答案相关信息可读”的证据，尚无足够证据说明这些方向被正常计算使用，或 self 的收益由某一特定内部机制产生。

5 自生成训练与置信度过滤：exp8

5.1 全量 self：小幅、跨切分不均匀的收益

表 5: 全量 self 的组合正确率（%，均值 ± 种子标准差）。每个切分 500 题，训练 864 条。

评估切分	基线	self	提升（pp）
A：新人物	39.0	47.87 ± 0.50	+8.87
B：新类别族	44.6	50.80 ± 1.60	+6.20
C：两者均新	49.6	53.13 ± 0.90	+3.53

来源：E8/E9。C 组种子为 53.2 / 52.2 / 54.0%；平均收益的种子 t 型 95% 区间为 [1.29, 5.77] pp。exp8 与 exp9 全量汇总结果相同，不将这两个汇总当作两份独立复现证据。

新人物、新类别族、两者均新的平均增益依次缩小，是值得关注的迁移模式。但三个切分的题目构成、基线与难度不同，尚未定义或控制“迁移距离”；因此这里仅说**跨切分收益不均匀**，不声称已经发现普适的距离衰减定律。

单步能力不能概括为“不下降”。在旧实验 C 组固定前 150 题上，第一步由 84.67% 到 86.44%，第二步由 74.00% 到 72.44%（三种子均值）。这一诊断子集与 exp10/11 的全部 500 题不同，不能直接拼接比较。〔S〕

5.2 更正确的目标，不必然带来更好的 C 组收益

表 6: exp8 全局筛选结果。目标正确率列为种子 0 对应子集的诊断；随机子集随种子变化。

条件	训练条数	目标正确率（%）	C 正确率（%）
全量 self	864	51.50	53.13 ± 0.90
全局置信度 50%	432	70.60	53.47 ± 0.95
全局随机 50%	432	49.77	54.07 ± 0.50
全局置信度 70%	605	61.49	52.80 ± 0.72
全局随机 70%	605	50.08	54.53 ± 0.31

来源：E8 的 `training_quality` 与原评分 C 组汇总。不同保留比例的数据量和优化步数不同；比较过滤策略时应在相同保留比例下比较。

置信度保留一半把目标正确率从 51.50% 提高到 70.60%，但 C 组没有相应优势；相同比例的随机筛选均值反而更高。全局筛选还改变类别构成，因此 exp9 补上类别内等量比较，避免将类别选择效应误认为答案质量效应。〔E8、E9〕

这些结果限制了一个简单策略：“只要更相信模型高置信度答案，就能更有效地向内学习”。它们不意味着目标正确性没有作用，也不意味着任何置信度或一致性信号都无用。

本节判断：全量 self 有可复核的小幅收益；当前置信度排序改善了目标标签质量，却没有稳定改善严格留出切分的训练效果。

6 对应关系与答案正确性：exp9、exp10

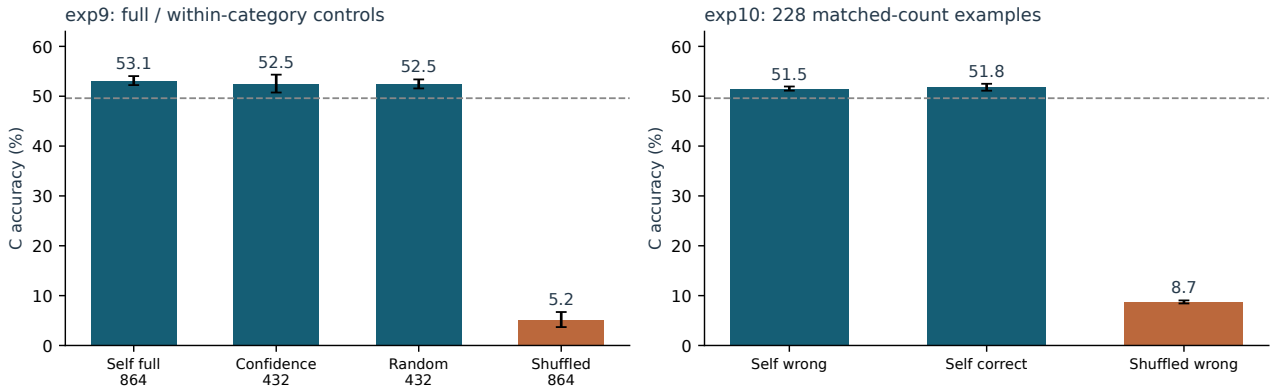


图 3: C 组对照，误差线为种子标准差。左右训练量不同：exp9 全量为 864 条，类别内半量为 432 条；exp10 各条件为 228 条。两图不得解释为同训练预算下的效果排序。来源：E9、E10。

6.1 打乱目标与类别内筛选

表 7: exp9：类别内错配造成严重退化；类别内置信度与随机筛选没有稳定差异。

条件	C 正确率（%）
exp9 全量 self（864 条）	53.13 ± 0.90
exp9 类别内打乱（864 条）	5.20 ± 1.51
exp9 类别内置信度（432 条）	52.53 ± 1.79
exp9 类别内随机（432 条）	52.47 ± 0.90

打乱全量相对 self 全量平均下降 47.93 pp，种子差值区间为 $[-53.25, -42.62]$ pp。类别内置信度相对随机平均仅 +0.07 pp，三个种子的差值方向不一致。不能把打乱的破坏仅归因于“违背模型认知”：题答对应关系、内容分布与训练冲突等同时变化。它支持**结构化对应关系有价值**，没有唯一识别出内在一致性机制。〔E9〕

6.2 自己的错答案与对答案

修订评分下，原池有 438 条对、426 条错。为使三个条件的类别配额一致，逐类别取正确 / 错误数量的较小值，得到 51、60、71、46 条，共 228 条；并非原先估计的约 419 条。self 错与打乱错使用同一批问题；self 对使用另一批问题，因此“正确性”的比较还混有问题难度与内容差异。〔E10、P〕

表 8: exp10 类别匹配后的 C 组结果（%）；单步列为三种子均值。

条件（各 228 条）	组合均值 ± SD	提升（pp）	第一步	第二步
self 错答案	51.53 ± 0.42	+1.93	84.13	78.27
self 对答案	51.80 ± 0.69	+2.20	84.47	77.27
打乱错答案	8.73 ± 0.31	-40.87	53.00	72.33

来源：E10，floor 评分；组合 / 第一步 / 第二步基线分别为 49.6 / 83.8 / 78.6%。

self 错减 self 对为 −0.27 pp，种子差值区间 $[-1.52, 0.98]$ pp；各种子的配对检验未检出差异。**未检出差异不等于等效**，也不意味着错答案在机制上与对答案相同。〔E10〕

本节判断：错误的自身目标也可能产生有限收益；目前证据尚不能把“内容正确性”和“与自身认知一致”干净分离。

7 迭代实验的设计与基线衔接：exp11

7.1 实际运行的三条路线

原计划把 216 位训练人物分成三份，每份得到 288 条，低于预设的 400 条阈值；因此实际每轮复用全部 864 条，只刷新目标。结果检验的是**固定问题池上的目标迭代**，不是持续吸收新人物数据。〔P、E11〕

共享 R1 以基础模型生成的目标训练。随后分为：

$$\begin{aligned} \text{重置:} \quad & \theta_k^R = \text{Train}(\theta_0, D, T(\theta_{k-1}^R)), \\ \text{接续:} \quad & \theta_k^C = \text{Train}(\theta_{k-1}^C, D, T(\theta_{k-1}^C)), \\ \text{固定目标:} \quad & \theta_k^F = \text{Train}_{k\ \text{倍轮次}}(\theta_0, D, T(\theta_0)). \end{aligned}$$

这里 T 是“自己回答第一步，再带入背景生成目标”的固定流程。重置路线每轮丢弃上一轮学生参数，仅接收上一轮目标；接续路线继承适配器，但重置优化器和调度器。固定目标路线从基础模型一次训练，匹配累计样本呈现次数和梯度步数。〔P〕

表 9: 预算匹配的含义；每个最终模型的唯一样本始终为 864 条。

路线	R2 链累计步数	R3 链累计步数	必须保留的差异
重置	432	648	最终一次拟合仍只有 216 步；前轮成本用于产生教师目标。
接续	432	648	继承适配器；分段重置优化器与学习率调度。
固定目标	432	648	一次连续训练；不支付逐轮刷新目标的同等生成成本。

来源：P 与 E11 运行配置。对应样本呈现次数为 R2 3,456、R3 5,184。匹配梯度预算不等于完整 FLOPs 或端到端计算成本匹配；优化日程也未完全一致。

共享 R1 加上三条路线各两个后续条件，共 7 个条件、3 个种子、21 次拟合。完成标记与全部阶段记录齐全；本次重新核算 94,500 个训练后评分标签（21 次 × 3 组 × 500 题 × 3 项指标）。各阶段计时合计约 5.34 小时，包含生成、加载与评估，不能称为纯训练时间。〔E11〕

7.2 为什么 49.6% 变成了 50.0%

本次逐题检查确认：exp11 与 exp8 的 A/B/C 评估**身份与顺序一致**，全量训练条数也相同。C 组基础模型重新生成时，18 条答案文本发生变化；其中 4 题从错到对、2 题从对到错，净增 2 题，故 248/500 变成 250/500。〔E11、B〕

新 C 组答案在旧评分与修订评分下的正确数同为 250；进一步逐题核验判定相同。**此处基线漂移来自预测变化，不能归因于评分切换**。具体是批处理、数值实现还是其他运行差异，当前证据未定位。exp11 应以自己的基线 50.0% 比较，不能借用 exp8 的 49.6%。

本节判断： exp11 的 R1 收益为 +2.53 pp，旧全量为 +3.53 pp；两者不是同一次运行的重复统计，也不能将差额直接解释为方法效果变化。

8 迭代结果：均值略升，但没有稳定预算优势

表 10: exp11 全部条件的组合正确率（%，均值 ± SD）。

条件	A：新人物	B：新类别族	C：两者均新
基础模型	38.20	44.40	50.00
共享 R1	48.33 ± 0.46	51.60 ± 1.11	52.53 ± 1.33
重置 R2	48.13 ± 0.50	52.27 ± 1.79	52.93 ± 1.10
重置 R3	47.40 ± 0.87	52.00 ± 1.04	53.53 ± 0.50
接续 R2	46.67 ± 0.64	52.33 ± 0.31	53.67 ± 0.95
接续 R3	47.40 ± 1.59	52.40 ± 1.25	53.67 ± 1.01
固定目标 / 2 轮预算	47.60 ± 0.40	52.47 ± 1.10	54.00 ± 1.06
固定目标 / 3 轮预算	48.67 ± 1.01	51.67 ± 1.53	52.73 ± 1.36

来源：E11，`groups`，`metric=composed`。固定目标 2 轮预算的 C 均值最高，不作测试集选优后部署推荐；完整条件同时列出。

重置路线的均值为 52.53% → 52.93% → 53.53%，仍有增长，不能写成“第二轮后没有增长”。接续路线为 52.53% → 53.67% → 53.67%，均值在后两轮持平，但不代表每个种子不变，更不等于到达参数或函数意义的不动点。〔E11〕

表 11: C 组关键配对差值与种子 t 型 95% 区间（pp）。区间基于相同训练种子的差值，三个种子使区间较宽。

比较	平均差值	95% 区间
重置 R2 − R1	+0.40	[-0.46, 1.26]
重置 R3 − R1	+1.00	[-3.55, 5.55]
重置 R3 − R2	+0.60	[-3.34, 4.54]
接续 R2 − R1	+1.13	[-0.61, 2.88]
接续 R3 − R2	+0.00	[-3.26, 3.26]
重置 R3 − 固定目标	+0.80	[-3.75, 5.35]
接续 R3 − 固定目标	+0.93	[-3.05, 4.92]

来源：E11，`C_paired_comparisons`。所列区间均包含 0；不能把均值顺序当成稳定优势。逐种子精确 McNemar 与 Holm 结果保存在附录所列文件。

重置 R3 相对 R1 为 +1.00 pp，但其中一个种子反而下降；接续 R3 相对固定目标 3 轮预算为 +0.93 pp，区间也很宽。固定目标本身从两轮预算到三轮预算下降，说明更多梯度步骤并不保证更好表现。〔E11〕

主 C 组的 54 项检验，经 Holm 校正后没有一项低于 0.05。这个结论不意味着效果严格为零：多重比较、仅三个种子及题目相关性都限制了辨别小效应的能力。但现有结果足以阻止“多轮持续自我提升已经成立”的表述。〔E11〕

本节判断：刷新目标尚未表现出稳定的额外收益。当前更合适的结论是“收益有限且对训练方式敏感”，而不是“迭代必然提升”或“整个向内学习方向已被否定”。

9 能力保留与信号质量：为什么还不能扩张结论

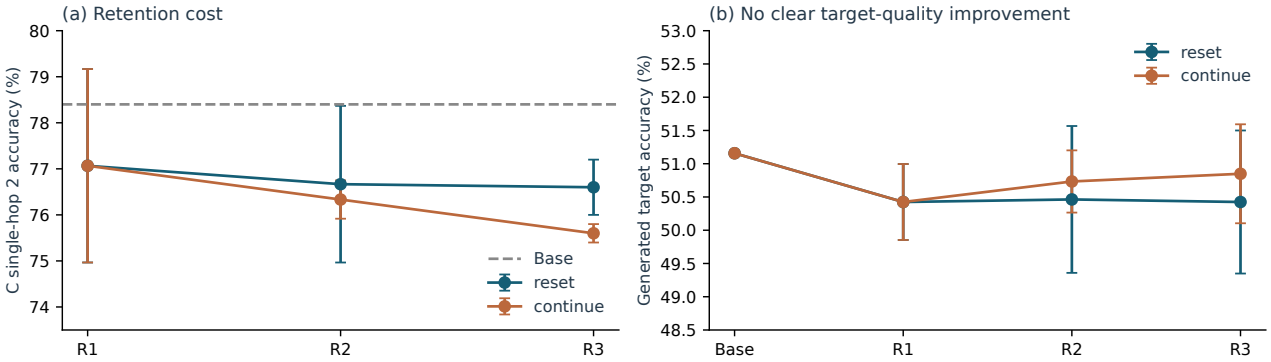


图 4: exp11 的两个约束。左：C 组第二步能力随训练下降的趋势；右：刷新后的目标正确率没有持续提高。误差线为种子标准差；目标由当前轮模型产生，R3 目标仅用于诊断，未训练 R4。来源：E11。

表 12: exp11 C 组单步正确率（%，均值 ± SD），均在全部 500 题评估。

条件	第一步	第二步
基础模型	82.80	78.40
共享 R1	84.87 ± 0.46	77.07 ± 2.10
重置 R2	85.20 ± 0.35	76.67 ± 1.70
重置 R3	85.40 ± 0.20	76.60 ± 0.60
接续 R2	84.20 ± 0.87	76.33 ± 0.42
接续 R3	84.07 ± 0.61	75.60 ± 0.20
固定目标 / 2 轮预算	84.47 ± 0.76	77.53 ± 0.83
固定目标 / 3 轮预算	83.87 ± 1.17	75.00 ± 1.91

来源：E11，`metric=hop1/hop2`。这里报告观察到的下降，不用“不显著”替代能力保持或非劣效检验。

表 13: 生成目标的质量与错误目标置信度。置信度为答案 token 平均 log probability；越接近 0，模型对生成串越确信，不是事实正确概率。

目标生成者	目标正确率均值（%）	错误目标平均 log probability
基础模型	51.16	-0.080
R1 生成	50.42	-0.059
重置 R2 生成	50.46	-0.036
重置 R3 生成	50.42	-0.028
接续 R2 生成	50.73	-0.018
接续 R3 生成	50.85	-0.008

来源：E11，`target_diagnostics`；各轮错误目标集合会变化，均值不构成同题校准比较。

错误训练目标的生成置信度上升，而目标正确率基本不变，提示自我强化风险。可是，在 C 组固定“各轮始终答错”的共同子集上，平均 log probability 并未一致单调上升。因此不能概括成“模型在测试集上越来越错、越来越自信”，更不能仅据置信度曲线宣称模型崩塌。〔E11〕

本节判断：评价迭代必须同时看组合收益、单步保留及信号质量；单看 C 组略升会遗漏可见的能力代价。

10 阶段结论、局限与路线选择

10.1 当前支持的四点结论

1. **知识利用是一个可操作的研究问题**。评分修订、共同样本分析与背景提示比较后，组合性缺口仍存在。〔G、A〕
2. **自生成目标具有有限监督价值**。全量 self 在留出切分出现小幅收益；对应关系被破坏时明显退化。证据限于当前任务、模型家族与训练设置。〔E8、E9〕
3. **简单质量代理尚不足够**。提高目标正确率的全局置信度过滤，没有转化为稳定 C 组优势；类别内对照也未建立稳定优势。〔E8、E9〕
4. **输出目标迭代尚未成为可靠的持续改进方法**。均值略升并存于预算对照无稳定优势、目标质量近乎不变和部分单步下降。〔E11〕

10.2 明确撤回或不采用的四类表述

1. “逻辑透镜可读，说明模型已经完成了中间推理”——可读性不足以确定因果使用。
2. “self 提升且单步能力不下降”——第二步存在回落，必须分开报告。
3. “错答案和对答案等效，说明模型在和自己对齐”——未检出差异不是等效，且训练问题未完全匹配。
4. “self 达到标准答案训练约一半效果 / 多轮收敛到不动点”——前者依赖未充分核验的单次对照，后者缺乏直接机制证据。

10.3 主要局限

外部有效性：只有一个模型家族与一种主要两跳事实结构，Qwen3 的规模比较不是第二模型家族复现；没有下游通用评测或产品收益测量。

统计与评分：每组有限测试题、仅三个训练种子；国家与人物共享带来相关性。别名评分仍可能误判；120 题分类未经过独立人工盲审；现有区间未联合覆盖题目与种子不确定性。旧、新基线生成存在漂移。

机制识别：self 与随机错配差异过大，只能排除部分简单解释；exp10 同时改变目标来源和问题集合。目标质量、风格、难度、输出分布与正则化效应尚未干净分离。

研究过程：评估集虽未用于梯度训练，却在多轮实验中反复查看；本阶段不是对全新封存基准的一次性确认。若进入下一阶段，应区分开发集与最终封存测试，而非在同一 C 组不断选择策略。

10.4 决策：保留问题，修订路线，暂不自动启动 exp12

按照阶段约定，以 exp11 作为决策检查点，而非新基准数据集。**建议修订方法后再投入：**保留“如何使模型更可靠地调用已有知识”的问题；暂不继续机械增加相同 self 迭代轮数。下一条路线应优先识别一个对组合成功有预测力、并能通过干预验证使用价值的自身信号，再判断其能否支持训练。

候选工作包括：在同一题与相同预算下区分信号可读和被使用；预先定义的跨结构迁移；第二模型家族复现；与上下文蒸馏、STaR 及知识组合机制工作的直接对照。这些是**待选择的研究路线**，不是已经授权或必然执行的实验清单。目标应是可重复、具有实际幅度且不以能力退化换取的收益，而不是预设“永不衰减或饱和”。

本节判断：本阶段的价值是缩小了问题与方法的边界：有值得研究的知识利用信号，但尚不足以支持通用迁移、持续自我提升或特定内部机制。下一笔算力应服务于路线判别。

A 完整性审计与历史待核实项目

A.1 本次重新核验的范围

本次报告构建读取原始结果与已保存分析，不修改历史实验文件。核对旧报告所用 40 个现存来源哈希；检查 exp11 的 21 次拟合完成标记、种子与预算，重新评分 94,500 个训练后标签并核算 C 组配对 McNemar；同时校验 exp9、exp10 的 C 组逐题结果与汇总一致。没有重新执行 GPU 训练，也没有补足历史缺失对照。

exp11 下载归档为 `exp11_685985_review.tgz`；本报告目录内保存其新解包副本 `raw_exp11/`。所有文件级 SHA-256 位于 `source_sha256.json`。代码与运行配置能追踪本地证据，但不等于已完成跨机器独立复现。

表 14: 历史记录中的待核实条目：仅作研究档案，不进入正文效果图或主结论。

实验	历史说法	本版处理
exp3	逐层搜索发现部分回填修复	缺原始逐题结果；待核实。
exp4	固定层修复约 14–16%，对照约 3%；历史 $p < 10^{-8}$	数字和检验待核实；不作图；不能遗漏破坏率。
exp5	门控后净收益约为 0	缺原始门控输出；待核实。
exp6	仅单步 C 为 49.8%；gold 为 56.8%（单次）	均待核实；不计算 self/gold 效果比。
exp6b	透镜变化支持 / 反对提前组合的机制解释	缺可完整复核的原始比较；不下机制结论。

来源仅为 H；上述数字并非本报告重新确认的结果。未发现原始文件，不等于实验未曾运行。

表 15: exp11 C 组全部种子结果（%），避免均值掩盖方向差异。

条件	种子 0	种子 1	种子 2	较基线均值（pp）
共享 R1	52.2	51.4	54.0	+2.53
重置 R2	52.4	52.2	54.2	+2.93
重置 R3	53.6	54.0	53.0	+3.53
接续 R2	54.0	52.6	54.4	+3.67
接续 R3	52.6	53.8	54.6	+3.67
固定目标 / 2 轮预算	54.8	52.8	54.4	+4.00
固定目标 / 3 轮预算	53.2	51.2	53.8	+2.73

A.2 汇报与邮件保持一致的表述

可以写：“自生成监督在严格留出切分上带来小幅提升，但第二步能力有所回落；当前迭代尚未稳定超过预算对照。”不应写：“已找到内部学习机制”“错目标与对目标等效”“获得通用持续学习能力”。

B 来源索引、图表映射与复现

所有路径相对于研究根目录。为便于阅读，正文用简短证据码；原始路径与完整哈希随报告保存。E11 为本报告目录中新解包的 raw_exp11/，其归档内父路径是 results/handoff_analysis_20261003/exp11_iterate/runs_685985/。

H INWARD_HANDOFF.md；历史设计与规范，不覆盖后续数据。

G results/handoff_analysis_20261003/tasks56_verified/gap_comparison.json；同目录 rescored_1.7B.jsonl、rescored_8B.jsonl、rescored_14B.jsonl。

A inward/results/handoff_analysis_20261003/verified_analysis/label_summary.json。

L inward/results/lens_Qwen3-14B/lens_items.jsonl、lens_summary.json；过滤派生值见 results/report_20261005/report_data.json 的 lens_filtered，算法见同目录 build_figures.py。

E8 results/handoff_analysis_20261003/exp8_680959/analysis/summary.json。

E9 results/handoff_analysis_20261003/exp9_681194/verified_analysis_v2/report.json；对应原始 runs_681194/*/eval_C_bothNew.jsonl 见哈希清单。

E10 results/handoff_analysis_20261003/exp10_681386/verified_analysis/report.json；对应 resumed_681332_681386/*/eval_C_bothNew.jsonl 见哈希清单。

E11 raw_exp11/analysis/report.json、stages.json、complete.json、plan/allocation.json；baseline/ 与各条件目录下 eval_*.jsonl、run_config.json、timing.json、各生成阶段 diagnostic.json。

B results/handoff_analysis_20261003/exp11_iterate/reference_exp8/eval_C_bothNew.jsonl 与 E11 的 baseline/eval_C_bothNew.jsonl。

S results/handoff_analysis_20261003/exp8_680959/results/filtered_680959/ 下 self_confidence_top1.0_s0/s1/s2 各目录的 inward_summary.json（此处为三个目录简称）。

P results/handoff_analysis_20261003/ 下 exp9_shuffled/、exp10_consistency/、exp11_iterate/ 的 protocol.json 和对应 Python 脚本；exp11 含 scoring_v2_v1.py。数据原件：inward/data/compositional_celebrities.json。

表 16: 图表与具体证据映射；每张图由 build_evidence.py 生成矢量 PDF。

对象	数据与字段
图 1；表 5	E8/E9 self_full A/B/C；E11 groups 的 C 组合均值与 SD。
图 2；表 3	G 的共同已知交集逐题重算；表 3 为 CLEAN/modes.floor。
图 3；表 7–8	E9 groups；E10 scoring.floor.groups，各自训练条数由协议限定。
图 4；表 12–13	E11 groups/metric=hop1,hop2、target_diagnostics。
表 1–2、9	H、P 与 E11 plan/allocation.json、各 run_config.json。
表 4、6	L 的重叠过滤派生值；E8 training_quality 与 groups。
表 10–11、15	E11 groups、C_paired_comparisons、逐题预测。
表 14	仅 H 的历史记录，全部待核实。

复现顺序：运行 python build_evidence.py，再运行 python build_report.py，最后用 XeLaTeX 或兼容 XeTeX 的 Tectonic 编译 inward_final_zh.tex。完整依赖与本次编译、视觉检查记录见 BUILD_README.txt。

参考文献

[1] Press, O., Zhang, M., Min, S., Schmidt, L., Smith, N. A., and Lewis, M. *Measuring and Narrowing the Compositionality Gap in Language Models*. 2022 预印本；Findings of EMNLP, 2023.

https://arxiv.org/abs/2210.03350

[2] Biran, E., Gottesman, D., Yang, S., Geva, M., and Globerson, A. *Hopping Too Late: Exploring the Limitations of Large Language Models on Multi-Hop Queries*. EMNLP, 2024.

https://arxiv.org/abs/2406.12775

[3] Snell, C., Klein, D., and Zhong, R. *Learning by Distilling Context*. 2022.

https://arxiv.org/abs/2209.15189

[4] Zelikman, E., Wu, Y., Mu, J., and Goodman, N. D. *STaR: Bootstrapping Reasoning With Reasoning*. NeurIPS, 2022.

https://arxiv.org/abs/2203.14465

[5] Liu, X., Liu, Y., Zhang, J., Zhang, Y., Zhang, K., and Liu, Q. *Layer-Order Inversion: Rethinking Latent Multi-Hop Reasoning in Large Language Models*. 2026.

https://arxiv.org/abs/2601.03542

文献使用边界

以上文献用于定位问题和方法关系，链接指向论文原始记录。本报告没有将他人的结果视为本项目的复现，也未据此声称方法新颖性已经确立。本阶段留下的核心开放问题是：如何定义一个模型可以自行生成、又确实预测后续可用性的监督信号；以及如何以有限算力区分信号改进、训练预算和记忆重整的贡献。